Análisis de Dataset

IntegraTrip · Tarea 3 · Traveling Magazine · versión reproducible local

7366	21	3.645.377	7366
chunks	ediciones	caracteres	IDs únicos

1. Alcance y metodología

El corpus reúne las 21 ediciones disponibles de Traveling Magazine, desde la 58 hasta la 78. Cada PDF se procesó con Docling sin OCR, HybridChunker y el tokenizer sentence-transformers/all-MiniLM-L6-v2. Los JSONL contienen texto contextualizado, revista, encabezados y páginas; los PDF originales permanecen fuera del repositorio.

Ediciones	58–78 (21 completas)
Chunks	7366
Rango de páginas	1–128
IDs duplicados	0
Grupos de texto exactamente duplicado	29
Chunks potencialmente editoriales/ruidosos	152

2. Temas, destinos y estructura

Las frecuencias no reemplazan la inspección semántica de Atlas, pero permiten auditar cobertura y orientar la exploración. Los términos dominantes se concentran en ciudad, historia, cocina, hotel, restaurante, vino, experiencia, cultura, gastronomía, naturaleza, museo y arquitectura.

Término	Apariciones
ciudad	1425
historia	1158
cocina	873
hotel	834
restaurante	798
solo	744
vino	743
lugar	742
experiencia	740
está	682
mundo	593
tradición	585

Destinos observables en encabezados

Entre los encabezados recurrentes aparecen Costa Rica, Estados Unidos, Colombia, México, Argentina, Suiza/Interlaken, Marrakech, Belfast, Innsbruck, Galicia, Alentejo, Zaragoza, Letur, Zamora y el Luberon. Esto muestra una mezcla de destinos internacionales y rutas regionales españolas.

Estructura editorial

Bienvenido a bordo	72
VIAJES	67
HISTORIA, ARTE Y CULTURA	50
Colaboran	46
ENOTURISMO	41
RESTAURANTES PROBADOS	35
LA VENTANA DE MANENA	32
VIAJES DE AUTOR	30
BODEGAS CON ALMA	27
LUGARES PARA SOÑAR	26
CONTENIDOS	25
Cómo llegar	23

3. Preguntas de exploración

La siguiente sección responde las preguntas solicitadas con evidencia local reproducible. Las tres búsquedas son una previsualización lexical sobre los chunks, útil para detectar cobertura y ruido antes de abrir Atlas. Deben confirmarse visualmente en el mapa público una vez creado el índice Nomic.

¿Qué temas aparecen?

Viajes y destinos, historia, arte y cultura, gastronomía, vinos y enoturismo, restaurantes, hoteles, naturaleza, arquitectura y experiencias locales.

¿Qué destinos aparecen?

Aparecen destinos de España y de otros países: Galicia, Alentejo, Madrid, Zaragoza, La Mancha, Luberon, Marrakech, Belfast, Innsbruck, Costa Rica, México, Colombia, Argentina y Suiza, entre otros.

¿Hay clusters?

La existencia y forma de los clusters debe verificarse en Atlas. La estructura editorial sugiere al menos cuatro familias: destinos/cultura, gastronomía/vino, hoteles/restaurantes y naturaleza/paisaje.

¿Hay chunks duplicados?

No hay IDs duplicados. La auditoría local encontró 29 grupos de texto exactamente repetido; este resultado debe compararse con la vista de duplicados de Atlas.

¿Hay chunks irrelevantes?

Sí hay candidatos editoriales que pueden aportar poco a una respuesta de viaje: encabezados como PUBLICIDAD, REDACCIÓN, DIRECTORA, COLABORAN, CONTENIDOS y PORTADA aparecen en 152 chunks. Se conservan para no alterar el corpus, pero deben vigilarse en retrieval.

4. Consultas de prueba

Las cifras siguientes son coincidencias textuales locales, no resultados de Atlas. Sirven como control de sanidad del corpus y como conjunto inicial de consultas para la exploración vectorial.

Consulta	Chunks con coincidencia	Ejemplo
playas	112	traveling59.pdf · pág. [6, 7]
castillos	18	traveling58.pdf · pág. [42]
comida romántica	203	traveling58.pdf · pág. [75]

Interpretación esperada

Las cifras cuentan chunks donde aparece al menos uno de los términos de la consulta (regla OR), por lo que son un control de cobertura y no una métrica de relevancia. playas debería recuperar destinos costeros y actividades de litoral; castillos debería concentrarse en patrimonio, historia y rutas; comida romántica puede requerir expansión semántica hacia restaurantes, cenas, parejas, vistas o atardeceres. En Atlas, estas tres búsquedas deben repetirse con el buscador vectorial y documentar los fragmentos más relevantes.

Estado de Atlas

El dataset ya fue publicado en Atlas con Projection ID fa545497-39bc-4f71-bbd8-a966e93d396e. Dataset: https://atlas.nomic.ai/data/maximiliano/integratrip-traveling-rag. Mapa: https://atlas.nomic.ai/data/maximiliano/integratrip-traveling-rag/map. La inspección visual de clusters, duplicados y búsquedas solicitadas debe completarse abriendo ese mapa.

5. Reproducibilidad y próximos pasos

Para regenerar este informe desde cero:

1. Descargar las ediciones 58–78 con scripts/rag/download_magazines.py.
2. Parsear con scripts/rag/parse_magazines.py.
3. Validar con scripts/rag/validate_chunks.py.
4. Analizar y generar este PDF con scripts/rag/analyze_corpus.py.
5. Crear el dataset Atlas con scripts/rag/upload_nomic.py y registrar en README el identificador y la URL pública.

Criterio de seguridad

La API key de Nomic sólo se lee desde el entorno del proceso server-side. No se guarda en el repositorio, no se incluye en el cliente ni se transmite al proxy LLM.

Conclusión

La etapa local del RAG está completa y auditada: corpus completo, metadatos de origen, herramienta local, contrato de búsqueda y documentación reproducible. El siguiente hito es abrir el mapa público, registrar las observaciones visuales y conectar su projection_id al despliegue.